

Hak-Bul - Veri Akisi & Qdrant Mimarisi

RAG pipeline veri katmani: ham veri -> chunking -> embedding -> Qdrant Cloud

1. Genel Veri Akisi

Tum veriler (kanun metinleri + Yargitay kararları) Qdrant Cloud'a yuklenir. Lokalde veri tutulmaz. Pipeline 4 asamalidir:

HAM VERI -> CHUNKING -> EMBEDDING -> QDRANT CLOUD

Mevzuat.gov.tr (XML / scraping)

chunk_kanun.py -> madde bazli bolme -> metadata ekle

data/processed/4857_is_kanunu_chunks.json -> load_qdrant.py -> Qdrant Cloud

data/processed/5510_sgg_kanunu_chunks.json -> load_qdrant.py -> Qdrant Cloud

data/processed/6098_turk_borclar_kanunu_chunks.json -> load_qdrant.py -> Qdrant Cloud

Kanun maddeleri de Qdrant'a yuklenir ve semantic arama ile sorgulanir. Her metin "passage: " prefix'i ile encode edilir.

Yargitay.gov.tr (HTML scraping)

chunk_yargitay.py -> ozet / gerekce / sonuc bolme -> metadata ekle

data/processed/yargitay_chunks.json -> load_qdrant.py -> Qdrant Cloud

Yargitay kararları da ayni sekilde "passage: " prefix'i ile encode edilip yuklenir.

2. Neyin Nerede Tutuldugu

Veri	Nerede	Arama Yontemi	Not
Kanun metinleri (4857, 5510, 6098)	Qdrant Cloud hukuk_chunks	Semantic (cosine similarity)	passage: prefix ile encode edilir
Yargitay kararları (500-1000 karar)	Qdrant Cloud hukuk_chunks	Semantic (cosine similarity)	passage: prefix ile encode edilir
Local JSON dosyaları (data/processed/)	Sadece disk (gecici)	-	Qdrant'a yuklendikten sonra gerekmiyor

Onemli: Tek bir Qdrant koleksiyonunda (hukuk_chunks) hem kanun hem Yargitay chunk'ları bulunur. kaynak_turu alanı ile ayirt edilir.

3. Ask Endpoint Sorgu Akisi

Kullanici sorusu geldiginde retriever.py tek bir Qdrant sorgusu yapar — kaynak_turu filtresi olmadan, her iki veri tipini birlikte getirir:

Adim	Islem	Detay
1	Query encode	model.encode("query: " + soru) multilingual-e5-base query prefix
2	Qdrant sorgu	Tek sorgu, kaynak_turu filtresi yok Hem kanun hem Yargitay sonuclari gelir
3	Skor filtresi	filter_by_score() ile dusuk skorlular elenir Varsayılan esik: 0.65
4	Yanıt uretme	Kalan chunk'lar Groq LLM'e gonder Kaynak atfli Turkce yanıt uret

Fallback: Qdrant erisilemediği durumda retriever.py otomatik olarak local keyword-based index'e geçer (QDRANT_URL bos veya bağlantı hatası).

4. load_qdrant.py Nasıl Çalışır?

Script tüm chunk tiplerini (kanun + yargıtay_kararı) alır, "passage: " prefix'i ile encode eder, Qdrant Cloud'a yükler.

Kullanım

```
# Koleksiyonu sıfırla ve tüm verileri yükle (ilk kurulum veya model değişimi)
python scripts/load_qdrant.py --recreate --input data/processed/

# Yuklenecek chunk sayısını önce kontrol et
python scripts/load_qdrant.py --dry-run --input data/processed/

# Tek dosya yükle
python scripts/load_qdrant.py --recreate --input
data/processed/4857_is_kanunu_chunks.json
```

İç İşleyiş

Adım	İşlem	Detay
1	JSON Yükle	data/processed/*.json dosyalarını oku (kanun + yargıtay)
2	Tip özeti	Her kaynak_turu için kaç chunk var, ekrana yaz
3	Koleksiyon	--recreate: eski koleksiyonu sil, yeniden oluştur (vector_size=768, distance=Cosine)
4	Encode	model.encode("passage: " + metin) <- her iki tip için aynı normalize_embeddings=True
5	Batch Upload	64'lük batch'ler halinde Qdrant'a upsert
6	Doğrula	Toplam vektor sayısı, boyut, distance bilgisi yazdırılır

5. Chunk JSON Formatları

Kanun chunk örneği

```
{
  "chunk_id": "kanun_4857_m17",
  "kaynak_turu": "kanun", // zorunlu
  "metin": "Madde 17 - ...", // zorunlu - encode edilecek
  "kanun_adi": "4857 Sayılı İis Kanunu",
  "madde_no": "Madde 17",
  "hukuk_alani": "is_hukuku",
  "yil": 2003,
  "url": "https://www.mevzuat.gov.tr/..."
}
```

Yargıtay chunk örneği

```
{
  "chunk_id": "yargitay_2023_1234_gerekce",
  "kaynak_turu": "yargitay_karari", // zorunlu
}
```

```
"metin": "...kidem tazminatına...", // zorunlu - encode edilecek
"karar_no": "2023/1234",
"daire": "9. Hukuk Dairesi",
"karar_bolumu": "gerekce", // ozet | gerekce | sonuc
"tarih": "2023-05-12",
"yil": 2023,
"url": "https://karararama.yargitay.gov.tr/..."
}
```

6. Qdrant'i Ne Zaman Yeniden Yuklemeli?

Senaryo	Yapilacak
Embedding modeli degisti (simdi: intfloat/multilingual-e5-base)	--recreate zorunlu Eski vektorler farkli uzayda, skorlar anlamsiz
Yeni kanun veya Yargitay verisi eklendi	--recreate VEYA sadece yeni chunk'lari upsert etmek yeterli
Koleksiyon bozuldu / test ortami	--recreate ile sifirla

7. Qdrant Koleksiyon Parametreleri

Parametre	Deger	Aciklama
Koleksiyon adi	hukuk_chunks	settings.COLLECTION_NAME (.env ile degistirilebilir)
Vector size	768	intfloat/multilingual-e5-base cikti boyutu
Distance metric	Cosine	Semantic benzerlik icin standart secim
Icerik	Kanun + Yargitay	Her iki tip ayni koleksiyonda, kaynak_turu ile ayirt edilir
Hedef vektor sayisi	~3.000-5.000	Kanun (~1.000-2.000) + Yargitay (~2.000-3.000)
Tahmini boyut	~18-30 MB	Qdrant free tier (1 GB) icin rahatlikla yeterli